

基于深度学习的 图像降噪算法

部门内部技术培训



2026年4月8日



算法研发部



图像恢复 Image Restoration

三大核心任务

图像去模糊

消除运动模糊、散焦模糊

$$y = k * x + n$$

k为模糊核

图像去雨

去除雨条纹、雨雾遮挡

$$y = x + R$$

R为雨纹层

图像降噪



消除传感器噪声，保留细节

$$y = x + n$$

n为噪声

效果对比示例

工业检测中最常见的需求



核心思路：从退化图像 y 中恢复干净图像 x。PSNR （ Peak Signal-to-Noise Ratio）峰值信噪比，单位为 dB（分贝），数值越高表示恢复图像与原始干净图像越接近，降噪效果越好。

图像降噪 Image Denoising

数学模型

$$y = x + n$$

y — 含噪图像

x — 干净图像（待恢复）

n — 噪声

常见噪声类型

✓ 高斯噪声

$$n \sim N(0, \sigma^2)$$

传感器热噪声、电子电路噪声

▮ 泊松噪声

与信号强度相关

光子计数不足（低光照）

⋈ 椒盐噪声

随机黑白像素点

传输错误、传感器坏点

⋈ 散粒噪声

泊松分布

CMOS/CCD 固有特性

↔ 加性 vs 乘性

高斯是加性，泊松/散粒与信号强度相关

▲ 空间相关性

各向同性高斯 vs 各向异性噪声（工业场景）



原图

高斯噪声



泊松噪声

椒盐噪声

有监督训练 Supervised Training

? 你手头有什么数据?

有干净+噪声配对

(LQ + HQ)

有监督训练

SwinIR ✓ Restormer ✓

只有噪声图像

(LQ only)

无监督/自监督

Noise2Noise

只有干净图像

(HQ only)

无监督/自监督

Noise2Self

☰ Step 1: 数据准备

● 方式A: 真实配对数据

同一场景拍摄两次（不同ISO/曝光） 例：SIDD数据集（手机真实噪声）

● 方式B: 人工合成配对 ← 常用

例：DIV2K、BSD500数据集

干净图 y + 人工加噪 $\rightarrow$ 噪声图 x

$$x = y + \sigma \cdot N(0, 1)$$

✂ Step 2: 数据增强 & Patch裁剪



随机裁剪 128×128 或
 256×256



随机水平/垂直翻转



随机旋转 $90^\circ/180^\circ/270^\circ$



保持配对一致性

SwinIR 基于 Swin Transformer 的图像恢复




Figure 2: The architecture of the proposed SwinIR for image restoration.




核心理念

将 Swin Transformer（移位窗口注意力）引入图像恢复领域



架构概要



关键特点



Swin Block

基本构建单元



移位窗口

局部注意力机制



$O(n^2) \rightarrow O(n)$

窗口内计算注意力



多任务支持

去噪·超分·去伪影



全局建模


克服CNN感受野受限



残差重建

精准修复高频细节

Restormer Efficient Transformer for High-Resolution Image Restoration



整体架构

两大核心创新模块

MDTA 多通道注意力

在通道维度计算注意力
复杂度 $O(C^2)$ ，与分辨率无关

 GDFN 门控前馈网络

门控机制控制信息流
类似 GLU 结构

Σ MDTA 关键公式

$$Q = W_Q \cdot X, \quad K = W_K \cdot X, \quad V = W_V \cdot X$$

$$\text{Attention} = \text{Softmax}(Q \cdot K^T / \alpha) \cdot V$$

← 在通道维度上计算

空间注意力

$O(H^2W^2)$

三 通道注意力

$O(C^2)$ ✓

核心优势: 通道注意力 $\rightarrow$ 计算量不随分辨率增长 $\rightarrow$ 适合高分辨率工业图像

工业场景降噪效果对比

